

22기 정규세션

ToBig's 21기 김세민

ToBig's 22기 송진하

SVM

Dimensionality Reduction

Contents


Unit 01 | SVM 정의

Unit 02 | Non-linear SVM

Unit 03 | Introduction of Dimensionality Reduction

Unit 04 | PCA, LDA

Unit 01 | SVM 정의




Support Vector Machine

주로 분류를 하기 위해 사용되는 기법이나 회귀에도 적용 가능.


주요 목적은 데이터를 분류하는 최적의 초평면(hyperplane)을 찾는 것.

Unit 01 | SVM 정의




데이터를 가장 잘 나눈 선은?

Unit 01 | SVM 정의




정답은 2번!

Unit 01 | SVM 정의




정답은 2번!


Unit 01 | SVM 정의



동그라미 분류X




둘 다 분류O



네모 분류X

Unit 01 | SVM 정의



Hyperplane

데이터 포인트를 분리하는 기준이 되는 평면(초평면)


Support Vector

클래스별로 Hyperplane과 가장 가까운 데이터

Margin

결정경계와 서포터 벡터 사이의 거리 $\times 2$

Unit 01 | SVM 정의



SVM 목표

마진을 최대화 하는 초평면을 찾는 것

Unit 01 | SVM 정의

Hyperplane

$$w \cdot x + b = 0$$


w 는 초평면의 법선 벡터 (초평면의 방향 결정)

x 는 데이터 포인트 벡터

b 는 초평면이 원점으로부터 얼마나 떨어져 있는지를 나타냄

Unit 01 | SVM 정의

Hyperplane



$$y_i(w \cdot x_i + b) \geq 1$$

$$y_i = \begin{cases} +1 & \text{for } \blacksquare \text{ sample} \\ -1 & \text{for } \bullet \text{ sample} \end{cases}$$

Unit 01 | SVM 정의

Margin (soft vs hard)

Hard Margin SVM

데이터가 선형적으로 완벽하게 분리 될 수 있는 경우에 사용
오분류 허용 X

Soft Margin SVM

데이터가 완벽하게 선형적으로 분리되지 않는 경우에 사용
현실 세계의 데이터는 노이즈와 이상치가 존재해 모든 데이터가 깔끔하게 선형적으로 나뉘지 않음
오분류 허용 O

Unit 01 | SVM 정의


Margin (soft vs hard)

Soft Margin SVM

분류기의 각 영역에 있을 때

- | | |
|-------------------------------|-----------|
| ① $(w \cdot x_i + b) \geq 1$ | Correct |
| ② $0 < (w \cdot x_i + b) < 1$ | Incorrect |
| ③ $(w \cdot x_i + b) < 0$ | Incorrect |

Slack variable(ξ_i) 사용



Unit 01 | SVM 정의

Margin (soft vs hard)

Soft Margin SVM

$$y_i(\mathbf{w} \cdot \mathbf{x}_i + b) \geq 1 - \xi_i$$

$$\xi_i \geq 0$$

Soft Margin SVM 목적 함수

$$\min \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i$$

$C \uparrow$ 오류 허용 \downarrow 모델의 복잡성 \uparrow

$C \downarrow$ 오류 허용 \uparrow 모델의 복잡성 \downarrow

Unit 01 | SVM 정의

Lagrange Multiplier Method

라그랑주 승수법이란 ?

최적화 문제를 제약 조건 하에서 해결하는 방법

SVM에서 최적의 초평면을 찾는 방법

목적 함수 $\min \frac{1}{2} \|w\|^2$

제약 조건 $subject\ to\ y_i(w^T \cdot x_i + b) \geq 1$

Unit 01 | SVM 정의

$$L(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_i \alpha_i [y_i(w \cdot x_i + b) - 1]$$

$$\frac{\partial L}{\partial w} = w - \sum_i \alpha_i y_i x_i = 0 \quad \Rightarrow \quad w = \sum_i \alpha_i y_i x_i \quad \frac{\partial L}{\partial b} = \sum_i \alpha_i y_i = 0$$

$$\frac{1}{2} \|w\|^2 = \frac{1}{2} w^T w$$

$$= \frac{1}{2} w^T \sum_{j=1}^n a_j y_j x_j$$

$$= \frac{1}{2} \sum_{j=1}^n a_j y_j (w^T x_j)$$

$$= \frac{1}{2} \sum_{j=1}^n a_j y_j (\sum_{i=1}^n a_i y_i x_i^T + x_j)$$

$$= \frac{1}{2} \sum_{j=1}^n \sum_{i=1}^n a_i a_j y_i y_j x_i^T x_j$$

$$- \sum_{i=1}^n a_i (y_i (w^T x_i + b) - 1) = - \sum_{i=1}^n a_i y_i (w^T x_i + b) + \sum_{i=1}^n a_i$$

$$= - \sum_{i=1}^n a_i y_i w^T x_i - b \sum_{i=1}^n a_i y_i + \sum_{i=1}^n a_i$$

$$= - \sum_{i=1}^n \sum_{j=1}^n a_i a_j y_i y_j x_i^T x_j + \sum_{i=1}^n a_i$$

Unit 01 | SVM 정의

$$\min_{w,b} \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i (y_i (w^T x_i + b) - 1) \longrightarrow \begin{aligned} &\underset{\alpha}{\text{maximize}} \sum_{i=1}^n \alpha_i - \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j \\ &\text{subject to } \sum_{i=1}^n \alpha_i y_i = 0, \\ &\alpha_i \geq 0, i = 1, 2, \dots, n \end{aligned}$$

듀얼 문제로 변환하면 계산 복잡성이 감소

후에 커널 트릭 사용하기에 용이

$$w = \sum_i \alpha_i y_i x_i \qquad y(w^T x + b) - 1 = 0$$

Unit 01 | SVM 정의


SVR

SVM의 회귀 버전

제한된 마진 오류 안에서 가능한 많은 샘플이 들어가도록 학습

폭은 하이퍼 파라미터 ε 로 조절


$\varepsilon \uparrow$ 폭 \uparrow $\varepsilon \downarrow$ 폭 \downarrow



Unit 02 | Non-Linear SVM

실제 데이터 중 선형적으로 분류할 수 없는 데이터셋이 많음

해결책으로 등장한 것이 커널 트릭





선형으로 분리 어려움



Unit 02 | Non-Linear SVM

Kernel Trick 이란?

원래 공간에서는 선형적으로 분리할 수 없는 데이터를 고차원 특성 공간으로 변환하여 선형적으로 분리할 수 있도록 하는 기술



Unit 02 | Non-Linear SVM



Unit 02 | Non-Linear SVM

일반적인 커널 함수들

Linear Kernel: 단순한 선형 관계 사용

$$K(x_i, x_j) = x_i \cdot x_j$$

Polynomial Kernel: 다항식 관계 모델링

$$K(x_i, x_j) = (x_i \cdot x_j + c)^d$$

RBF or Gaussian Kernel: 데이터 간의 거리를 측정해 유사도 계산

$$K(x_i, x_j) = \exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma^2}\right)$$

Sigmoid Kernel: 뉴럴 네트워크의 활성화 함수와 유사한 형태

$$K(x_i, x_j) = \tanh(\alpha x_i \cdot x_j + c)$$

Unit 02 | Non-Linear SVM

Kernel Trick

$$\max L_D(\alpha_i) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \Phi(x_i)^T \Phi(x_j)$$



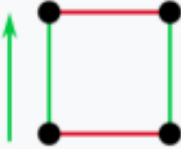
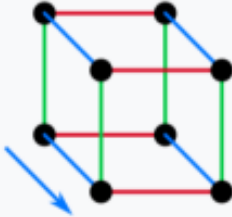
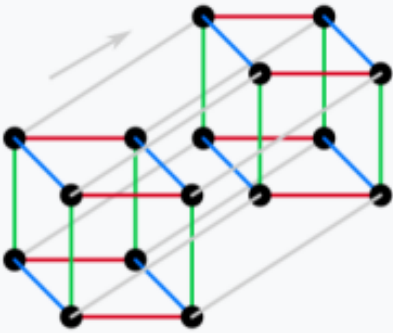

SVM의 듀얼 문제는 데이터 포인트 간의 내적만을 포함

커널 함수를 사용해 직접 고차원 공간으로 데이터를 변환하지 않고도 고차원 공간에서의 연산을 원래 공간에서 수행 가능

Unit 03 | Introduction of Dimensionality Reduction

차원이란?

공간의 성질을 나타내는 수로 공간에서 독립적으로 움직일 수 있는 방향의 개수

					<div><div>X</div><div>Y</div><div>Z</div><div>W</div></div>
0	1	2	3	4	#Dim

Unit 03 | Introduction of Dimensionality Reduction

차원이란?

데이터를 구성하고 있는 속성의 개수


번호	수학1	확.통	물리	물리실험	미술	체육
1	80	85	75	80	40	60
2	30	32	25	30	90	55
3	70	75	90	92	80	50
4	40	32	54	40	90	70
5	95	90	100	95	60	90

Unit 03 | Introduction of Dimensionality Reduction

차원의 저주란?

차원이 증가함에 따라 데이터 분석 및 알고리즘 성능에 악영향을 미치는 다양한 현상

데이터 희소성, 계산 복잡도 증가, 과적합, 거리 측정의 신뢰성 감소 등



Unit 03 | Introduction of Dimensionality Reduction

차원의 저주 극복 방법

차원 축소: 데이터의 차원을 줄임

특징 선택: 모델 성능에 중요한 영향을 미치는 주요 특징만 선택해 사용해 불필요한 차원 제거

정규화: 모델이 복잡해지는 것을 방지하기 위해 정규화 기법 사용해 과적합 방지

Unit 03 | Introduction of Dimensionality Reduction

차원 축소

번호	수학1	확.통	물리학	물리실험	미술	체육
1	80	85	75	80	40	60
2	30	32	25	30	90	55
3	70	75	90	92	80	50
4	40	32	54	40	90	70
5	95	90	100	95	60	90

특징 선택



번호	수학1	물리학	미술
1	80	75	40
2	30	25	90
3	70	90	80
4	40	54	90
5	95	100	60

특징 추출



번호	이과	미술
1	77.5	40
2	27.5	90
3	80	80
4	47	90
5	97.5	60

$$\text{이과} = (\text{수학1} + \text{물리학}) / 2$$

Unit 03 | Introduction of Dimensionality Reduction

차원 축소

번호	수학1	확.통	물리학	물리실험	미술	체육
1	80	85	75	80	40	60
2	30	32	25	30	90	55
3	70	75	90	92	80	50
4	40	32	54	40	90	70
5	95	90	100	95	60	90

특징 선택



번호	수학1	물리학	미술
1	80	75	40
2	30	25	90
3	70	90	80
4	40	54	90
5	95	100	60

특징 추출



번호	이과	미술
1	77.5	40
2	27.5	90
3	80	80
4	47	90
5	97.5	60


$$\text{이과} = (\text{수학1} + \text{물리학}) / 2$$

PCA
LDA

Unit 04 | PCA, LDA

Principal Component Analysis (주성분 분석)

데이터의 변동성을 최대한 보존하면서 고차원 데이터를 저차원으로 축소하는 것

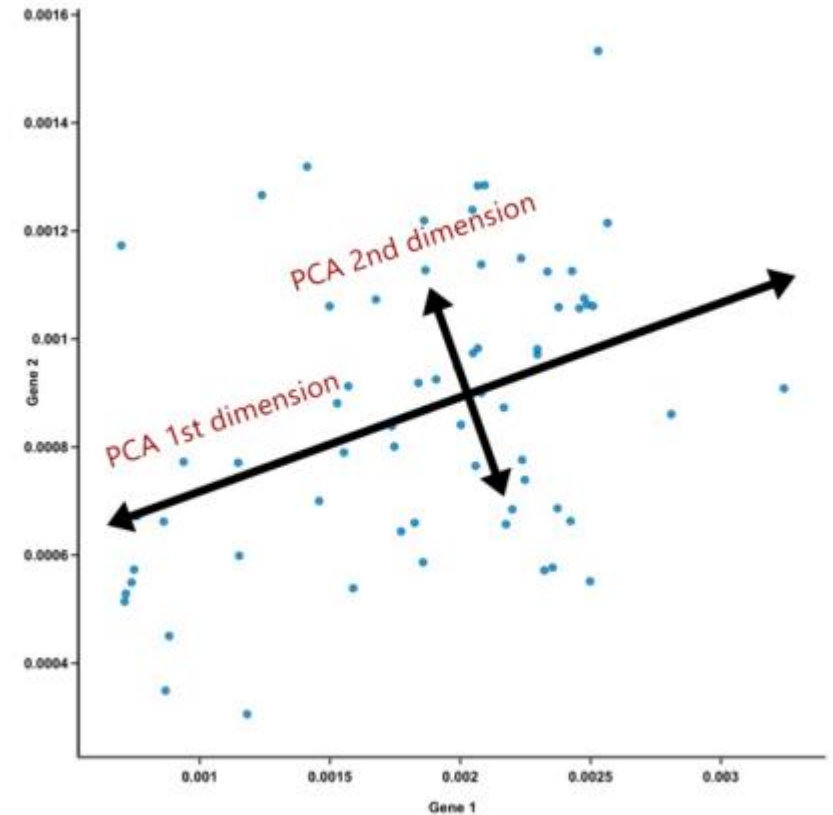


Unit 04 | PCA, LDA

Principal Component Analysis 과정

데이터의 분산을 최대화하는 방향으로 새로운 축(주성분)을 찾는다.


1. 분산이 가장 큰 벡터 선택
2. 첫 번째 벡터와 직교하는 벡터 중 분산이 가장 큰 벡터 선택
3. 두 번째 벡터와 직교하는 벡터 중 분산이 가장 큰 벡터 선택
4. 위와 같은 과정을 반복



Unit 04 | PCA, LDA

Principal Component Analysis 결과

사전에 정의한 N개의 벡터를 선택한 후, N개의 벡터가 나타내는 공간에 투영



Unit 04 | PCA, LDA

최대 분산을 선택하는 이유


분산이 큰 벡터가 중요한 정보를 담고 있다고 가정



Unit 04 | PCA, LDA

직교 벡터를 선택하는 이유


직교 벡터는 상호 독립적이어서 데이터의 중요한 정보를 중복 없이 독립적으로 설명 가능



Unit 04 | PCA, LDA

Linear Discriminant Analysis (선형 판별 분석)

클래스 간의 거리가 최대가 되게 하면서
클래스 내의 분산이 최소가 되게 하는 벡터를 찾음




Unit 04 | PCA, LDA

LDA와 PCA의 비교

PCA: 데이터의 전체 변동성을 최대화하는 방향으로 데이터 변환

LDA: 클래스 간 분리를 최대화 하는 방향으로 데이터 변환

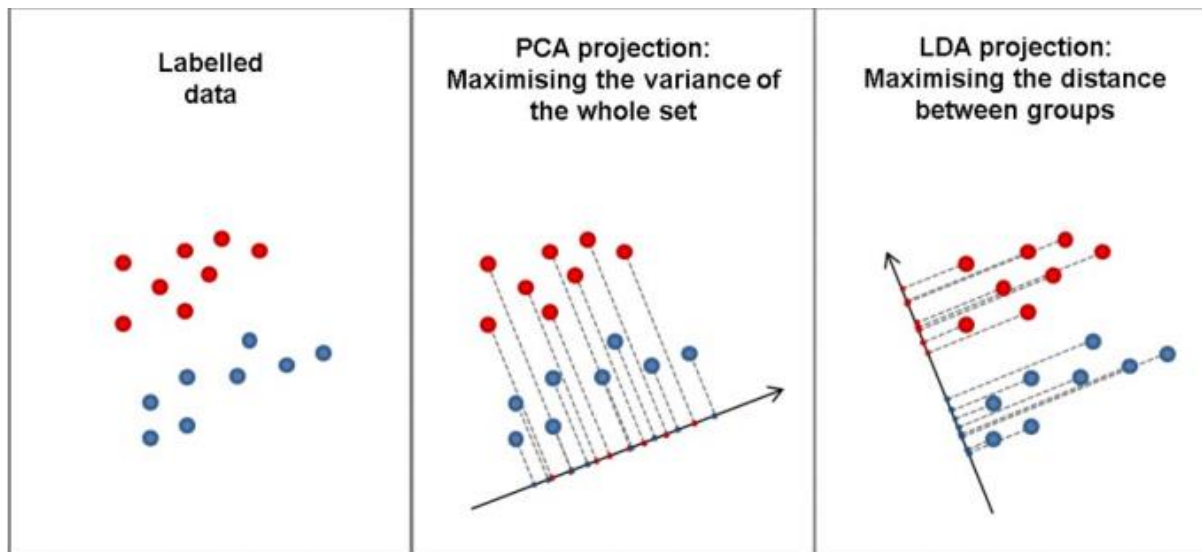


Unit 04 | PCA, LDA

LDA와 PCA의 비교

PCA: 데이터의 분산이 가장 큰 벡터 선택, 비지도 학습 (클래스 레이블 정보 사용X)

LDA: 클래스 간 분리를 최대화 하는 방향으로 데이터 변환, 지도 학습(클래스 레이블 정보 사용O)






Unit 04 | PCA, LDA

Linear Discriminant Analysis 과정

1. 데이터 준비
2. 클래스별 평균 벡터 계산
3. 클래스 내 공분산 행렬(S_W)과 클래스 간 공분산 행렬(S_B) 계산
4. 클래스 간 분산을 최대화 하고 클래스 내 분산을 최소화하는 변환 행렬 계산
5. S_W 의 역행렬과 S_B 를 곱한 행렬의 고유값을 계산해 가장 큰 고유값에 해당하는 고유벡터 선택
6. 원본 데이터를 변환 행렬로 변환해 새로운 저차원 공간에 투영

Unit 04 | PCA, LDA

Linear Discriminant Analysis 결과



Unit 00 | 실습


SVM & Dimensionality Reduction

- Iris 데이터셋에 대해 svm 분류 수행 및 커널 별 시각화
- Pca와 lda를 활용하여 분류 수행 및 결과 시각화

Unit 00 | 과제

Multiclass SVM

- 이제껏 공부한 SVM 모델은 hyperplane을 기준으로 데이터를 이진 분류하는데 초점이 맞춰져 있음
 - Class가 여러 개인 경우에는?
- One vs One (OvO)
 - N개의 클래스가 있을 때, 모든 클래스에 대해 1:1로 이진 분류를 진행
 - ➔ Voting 기법으로 최종 예측 클래스 결정
- One vs Rest (OvR)
 - N개의 클래스가 있을 때, 모든 클래스에 대해 1 : N-1로 이진 분류를 진행
 - ➔ 가장 높은 점수를 내는 클래스를 최종 예측 클래스로 결정



Unit 00 | 과제

Multiclass SVM

과제: 내 손으로 만드는 DIY SVM★

(1) SVM from scratch

- Numpy만을 사용하여 SVM Classifier 구현
- 참고 사이트 (과제 파일 참조)에 있는 코드 및 구현 방법을 참고하여 SVM의 가중치 업데이트 식과 predict 함수를 올바르게 작성해주시면 됩니다.

(2) Dimensionality Reduction

- Pca와 lda를 사용하여 MNIST 데이터셋의 차원을 축소시킨 뒤, 앞서 구현한 SVM Classifier로 분류 작업을 수행해주세요.



Unit 00 | 과제


Multiclass SVM

과제: 내 손으로 만드는 DIY SVM★

(3) Multiclass SVM

- 기본적인 사이킷런 SVM 클래스는 다중 분류 기능을 지원하지만 여기서는 사용하시면 안됩니다. 1번 과제에서 구현한 SVM Classifier을 사용하셔야 합니다.
- **OvO 방법론**을 기반으로 하여 구현하고, 결과를 출력해주세요. (accuracy score, classification report, etc.)
- 사이킷런의 공식 문서를 참고하여 구현하여도 무방합니다.
- 만약 voting 결과가 동점으로 나왔을 시에는 임의로 처리 방식을 결정해주세요.
 - Ex) decision function 이용, 가장 개수가 많은 클래스 활용, 랜덤으로 선택 등등

When your program
is a complete mess,
but it does its job



Unit 00 | 출처

<https://kr.mathworks.com/discovery/support-vector-machine.html>

<https://m.blog.naver.com/wooy0ng/222667389075>

<https://velog.io/@cyeongy/SVM-Support-Vector-Machine>

<https://m.blog.naver.com/jaehong7719/221928401297>

ToBig's 20기 박준 님 강의자료

ToBig's 20기 양승빈 님 강의자료

<https://velog.io/@gangjoo/ML-%EC%B0%A8%EC%9B%90-%EC%B6%95%EC%86%8C-LDA-Linear-Discriminant-Analysis>

<https://towardsdatascience.com/support-vector-machine-introduction-to-machine-learning-algorithms-934a444fca47>

https://velog.io/@claude_ssim/%EA%B8%B0%EA%B3%84%ED%95%99%EC%8A%B5-Multi-Class-Classification-and-Kernel-Method



Q & A

들어주셔서 감사합니다.